# Министерство науки и высшего образования Российской Федерации Федеральное государственное автономное образовательное учреждение высшего образования «СЕВЕРО-КАВКАЗСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»

Институт перспективной инженерии Департамент цифровых, робототехнических систем и электроники

# ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №5 дисциплины «Искусственный интеллект и машинное обучение» Вариант 6

Выполнил:
Якушенко Антон Андреевич
2 курс, группа ИТС-б-о-23-1,
11.03.02 «Инфокоммуникационные
технологии и системы связи»,
направленность (профиль)
«Инфокоммуникационные системы и
сети», очная форма обучения
(подпись)
Проверил:
Ассистент департамента цифровых,
робототехнических систем и
электроники Хацукова А.И
ı
(подпись)

# TEMA: ВВЕДЕНИЕ В PANDAS: ИЗУЧЕНИЕ СТРУКТУРЫ DATAFRAME И БАЗОВЫХ ОПЕРАЦИЙ

**Цель работы:** познакомить с основами работы с библиотекой pandas, в частности, со структурой данных DataFrame.

Ссылка на репозиторий: https://github.com/Yakush766/LB5AI.git

## Порядок выполнения работы:

1. Перед выполнением заданий установил окружение conda с версией python 3.12.7

```
(base) C:\Users\anton\Documents\Икусственный интелект и машинное обучение\LB5AI>conda create --name myenv python=3.12.7
Channels:
    - defaults
Platform: win-64
Collecting package metadata (repodata.json): done
Solving environment: done

## Package Plan ##

environment location: C:\Users\anton\.conda\envs\myenv

added / updated specs:
    - python=3.12.7
```

Рисунок 1. Установка окружения conda

2. Далее активировал окружение и добавил его как ядро в jupyter lab

```
(base) C:\Users\anton\Documents\Икусственный интелект и машинное обучение\LB5AI>conda activate myenv (myenv) C:\Users\anton\Documents\Икусственный интелект и машинное обучение\LB5AI>
```

Рисунок 2. Активация окружения



Рисунок 3. Добавление окружения в качестве ядра

3. Далее установил и подключил все необходимые утилиты для работы в своё окружение: black, flake8, isort и pre-commit.

(myenv) C:\Users\anton\Documents\Икусственный интелект и машинное обучение\LB5AI> pip install black flake8 isort pre-commit

Рисунок 3. Установка утилит

Рисунок 4. Добавление конфигурационного файла для black

Рисунок 5. Добавление конфигурационного файла для flake8

Рисунок 6. Добавление конфигурационного файла для isort

```
- repo: https://github.com/psf/black
3
           rev: 23.12.1 # Используйте последнюю версию Black
4
           hooks:
5
             - id: black
6
               language_version: python3
7
8
          - repo: https://github.com/pycqa/isort
9
           rev: 5.13.2 # Используйте последнюю версию isort
10
           hooks:
11
             - id: isort
12
               name: isort (python3)
13
               language_version: python3
14
         - repo: https://github.com/PyCQA/flake8
15
16
           rev: 6.1.0 # Используйте последнюю версию Flake8
17
           hooks:
18
             - id: flake8
19
               additional_dependencies: ["flake8-bugbear"] #Добавление дополнительных проверок
```

Рисунок 7. Добавление конфигурационного файла для pre-commit

После того как мы выполнили все действия у нас появилась вот такая кнопка для форматирования кода.

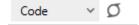


Рисунок 8. Кнопка форматирования

Далее нажимаем на неё и наш код форматируется.

```
import numpy as np
import pandas as pd
# Данные из таблицы для создания словаря списков
data_dict = {
    "ID": [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20],
    "Имя": [
        "Иван",
        "Ольга",
        "Алексей",
        "Мария",
        "Сергей",
        "Анна",
        "Дмитрий",
        "Елена",
        "Виктор",
        "Алиса",
        "Павел",
        "Светлана",
        "Роман",
        "Татьяна",
        "Николай",
        "Валерия",
        "Григорий",
        "Юлия",
        "Степан",
        "Василиса",
    "Возраст": [
       25,
        30,
        40,
        35,
        28,
        32,
        45,
        29,
        31,
        27,
        33,
        26,
        42,
        37,
        39,
        24,
        50,
        45,
        41,
        38,
```

Рисунок 9. Пример использования утилит

## Задание 1. Создание DataFrame разными способами

#### Рисунок 10. Код для выполнения задания

```
import numpy as np
import pandas as pd
# Данные из таблицы для создания словаря списков
data_dict =
     "ID": [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20],
         "Иван"
         "Ольга"
         "Алексей",
         "Мария",
"Сергей",
         "Дмитрий",
         "Елена",
"Виктор",
         "Павел",
         "Роман",
"Татьяна",
         "Николай"
         "Валерия",
         "Григорий",
         "Степан".
         "Василиса",
    ],
"Возраст": [
         25,
30,
         40,
         28,
         32,
         45,
         29,
         42,
         37,
         24.
         45.
```

Рисунок 11. Пример использования утилит

DataFrame из словаря списков:									
	ID	РМИ (	Возраст	Должность	Отдел	Зарплата	١		
0	1	Иван	25	Инженер	IT	60000			
1	2	Ольга	30	Аналитик	Маркетинг	75000			
2	3	Алексей	40	Менеджер	Продажи	90000			
3	4	Мария	35	Программист	IT	80000			
4	5	Сергей	28	Специалист	HR	50000			
5	6	Анна	32	Разработчик	IT	85000			
6	7	Дмитрий	45	HR	HR	48000			
7	8	Елена	29	Маркетолог	Маркетинг	70000			
8	9	Виктор	31	Юрист	Юридический	95000			
9	10	Алиса	27	Дизайнер	Дизайн	62000			
10	11	Павел	33	Администратор	Администрация	55000			
11	. 12	Светлана	26	Тестировщик	Тестирование	67000			
12	13	Роман	42	Финансист	Финансы	105000			
13	14	Татьяна	37	Редактор	Редакция	72000			
14	15	Николай	39	Логист	Логистика	75000			
15	16	Валерия	24	SEO-специалист	SE0	64000			
16	17	Григорий	50	Бухгалтер	Бухгалтерия	110000			
17	18	Юлия	45	Директор	Финансы	150000			
18	19	Степан	41	Экономист	Экономика	98000			
19	20	Василиса	38	Проект-менеджер	Продажи	88000			
	-								
	Ста	ж работы							
0 1		2 5							
2									
3		15 7							
4		3							
5									
6		6 12							
7		4							
8		10							
9		5							
10		7							
11		2							
12		20							
13									
14		9 11							
15		3							
16		25							
17		20							
18		14							
19	,	8							

Рисунок 12. Выполненное задание

#### Задание 2. Чтение данных из файлов ( CSV , Excel , JSON)

```
# Создаём DataFrame с вашими данн
 data_employees =
       "ID": [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20].
      "Има": ["Иван", "Ольга", "Алексей", "Мария", "Сергей", "Анна", "Дмитрий", "Елена", "Виктор", "Алиса",

"Павел", "Сестлана", "Роман", "Татъяна", "Николай", "Валерия", "Григорий", "Юлия", "Степан", "Василиса"],
"Возраст": [25, 30, 40, 35, 28, 32, 45, 29, 31, 27, 33, 26, 42, 37, 39, 24, 50, 45, 41, 38],
      "Должность": ["Инженер", "Менадиер", "Порграммист", "Специалист", "Сводначики", "Павустолог", "Юрист", "Дизайнер",

"Администратор", "Тестировщик", "Финансист", "Специалист", "Сводначики", "Павустолог", "Бухгалтер", "Директор", "Экономист", "Проект-менеджер"],

"Отдел": ["IT", "Маркетинг", "Продажи", "IT", "Ня", "Пя", "Ня", "Маркетинг", "Бухгалтерт", "Дирайн",

"Администрация", "Тестирование", "Финансист", "Перистика", "Бог, "Духгалтерия", "Экономика", "Продажи"],

"Зарплата": [60000, 75000, 90000, 80000, 80000, 85000, 48000, 70000, 95000, 62000, 55000, 67000, 105000, 72000, 75000, 64000, 110000, 150000, 98000, 88000],
       "Стаж работы": [2, 5, 15, 7, 3, 6, 12, 4, 10, 5, 7, 2, 20, 9, 11, 3, 25, 20, 14, 8]
data clients = {
      df_employees = pd.DataFrame(data_employees)
df_clients = pd.DataFrame(data_clients)
# 1. Сохранение таблицы в CSV и чтение обра
csv filename = 'Таблица1.csv
df_employees.to_csv(csv_filename, index=False)
df_csv = pd.read_csv(csv_filename)
print("Первые 5 строк из CSV файла:")
print(df csv.head())
excel filename = 'Таблица2.xlsx
df_employees.to_excel(excel_filename, index=False, sheet_name='Employees')
df_excel = pd.read_excel(excel_filename, sheet_name='Employees')
print("\nПервые 5 строк из Excel файла:")
print(df excel.head())
json_filename =
                       'Таблица1.json'
df_employees.to_json(json_filename, orient='records')
with open(json_filename, 'r', encoding='utf-8') as f:
     data_json = json.load(f)
print("\nПервые 5 элементов из JSON файла:")
for item in data_json[:5]:
    print(item)
```

#### Рисунок 13. Код для выполнения задания

```
Первые 5 строк из CSV файла:
     ID
                   Имя Возраст Должность
                                                                                 Отдел Зарплата Стаж работы
                  Иван 25
                                                                                              60000
     1
                                                     Инженер
                                                                                 IT
                                      30 Аналитик Маркетинг
40 Менеджер Продажи
1 2
               Ольга
                                                                                                   75000
                                                                                                                                    5
            Алексей 40 Менеджер
Мария 35 Программист
2
      3 Алексей
                                                                                                   90000
                                                                                                                                  15
                                                                            IT
    4
3
                                                                                                  80000
                                                                                                   50000
4
      5 Сергей
                                      28 Специалист
                                                                                     HR
Первые 5 строк из Excel файла:
                  Имя Возраст Должность Отдел Зарплата Стаж работы
     ID
0 1 Иван 25 Инженер IT 60000
1 2 Ольга 30 Аналитик Маркетинг 75000
2 3 Алексей 40 Менеджер Продажи 90000
3 4 Мария 35 Программист IT 80000
4 5 Сергей 28 Специалист HR 50000
                                                                                                                                  2
                                                                                                                                 15
Первые 5 элементов из JSON файла:
Тервые 5 элементов из узом фаила: ('ID': 1, 'Имя': 'Иван', 'Возраст': 25, 'Должность': 'Инженер', 'Отдел': 'IT', 'Зарплата': 60000, 'Стаж работы': 2} ('ID': 2, 'Имя': 'Ольга', 'Возраст': 30, 'Должность': 'Аналитик', 'Отдел': 'Маркетинг', 'Зарплата': 75000, 'Стаж работы': 5} ('ID': 3, 'Имя': 'Алексей', 'Возраст': 40, 'Должность': 'Менеджер', 'Отдел': 'Продажи', 'Зарплата': 90000, 'Стаж работы': 15} ('ID': 4, 'Имя': 'Мария', 'Возраст': 35, 'Должность': 'Программист', 'Отдел': 'IT', 'Зарплата': 80000, 'Стаж работы': 7} ('ID': 5, 'Имя': 'Сергей', 'Возраст': 28, 'Должность': 'Специалист', 'Отдел': 'НR', 'Зарплата': 50000, 'Стаж работы': 3}
```

Рисунок 14. Выполненное задание

#### Задание 3. Доступ к данным (.loc,.iloc,.at,.iat)

```
import pandas as pd
 # Создаём таблицу
      а= {
    "ID": [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20],
    "Имя": ["Иван", "Ольга", "Алексей", "Мария", "Сергей", "Анна", "Дмитрий", "Елена", "Виктор", "Алиса",
    "Павел", "Светлана", "Роман", "Татьяна", "Николай", "Валерия", "Григорий", "Юлия", "Степан", "Василиса"],
    "Возраст": [25, 30, 40, 35, 28, 32, 45, 29, 31, 27, 33, 26, 42, 37, 39, 24, 50, 45, 41, 38],
    "Должность": ["Инженер", "Аналитик", "Менеджер", "Программист", "Специалист", "Разработчик", "НЯ", "Маркетолог", "Дизайнер",
    "Амминистратор", "Тестировацик", "Финансист", "Редактор", "Логист", "5ЕО-специалист", "Бухгалтер", "Директор", "Экономист", "Проект-менеджер"],
    "Отдел": ["II", "Маркетинг", "Продажи", "IT", "НЯ", "II", "НЯ", "Погистика", "5ЕО", "Бухгалтерия", "Финансы", "Экономика", "Продажи"],
    "Зарплагат: [60000, 75000, 90000, 80000, 50000, 50000, 48000, 70000, 95000, 55000, 67000, 105000, 72000, 75000, 64000, 110000, 150000, 98000, 88000],
    "Стаж работы": [2, 5, 15, 7, 3, 6, 12, 4, 10, 5, 7, 2, 20, 9, 11, 3, 25, 20, 14, 8]
         "Стаж работы": [2, 5, 15, 7, 3, 6, 12, 4, 10, 5, 7, 2, 20, 9, 11, 3, 25, 20, 14, 8]
df = pd.DataFrame(data)
 # Устанавливаем TD как индекс
df.set_index('ID', inplace=True)
print("Информация о сотруднике с ID=5:\n", employee_id_5)
# 2. Вывести возраст третьего сотрудника (позиция 2) age third employee = df.iloc[2]['Возраст']
print("Возраст третьего сотрудника:", age_third_employee)
# 3. Название отдела для сотрудника "Мария
row_maria = df[df['Имя'] == 'Мария']
department_maria = df.at[row_maria.index[0], 'Отдел']
print("Отдел Марии:", department_maria)
# 4. Зарплата в 4-й строке и 5-м столбце (нумерация с 0)
salary = df.iat[3, 4]
print("Зарплата в 4-й строке, 5-м столбце:", salary)
# 5. Объяснение разницы между методами:
.loc[] - по меткам (имена индексов и колонок)
.iloc[] - по числовым позициям
 .at[] - быстрый доступ к одному элементу по метке
 .iat[] - быстрый доступ к одному элементу по позиции
```

#### Рисунок 15. Код для выполнения задания

```
Информация о сотруднике с ID=5:
Имя
                   Сергей
Возраст
Должность Специалист
Отдел
                     HR
                   50000
Зарплата
Стаж работы
Name: 5, dtype: object
Возраст третьего сотрудника: 40
Отдел Марии: IT
Зарплата в 4-й строке, 5-м столбце: 80000
.loc[] - по меткам (имена индексов и колонок)
.iloc[] - по числовым позициям
.at[] - быстрый доступ к одному элементу по метке
.iat[] - быстрый доступ к одному элементу по позиции
```

Рисунок 16. Выполненное задание

# Задание 4. Добавление новых столбцов и строк

# Рисунок 17. Код для выполнения задания

	ID	ВМИ	Возраст	Должность	Отдел	Зарплата
0	1	Иван	25	Инженер	IT	60000
1	2	Ольга	30	Аналитик	Маркетинг	75000
2	3	Алексей	40	Менеджер	Продажи	90000
3	4	Мария	35	Программист	IT	80000
4	5	Сергей	28	Специалист	HR	50000
5	6	Анна	32	Разработчик	IT	85000
6	7	Дмитрий	45	HR	HR	48000
7	8	Елена	29	Маркетолог	Маркетинг	70000
8	9	Виктор	31	Юрист	Юридический	95000
9	10	Алиса	27	Дизайнер	Дизайн	62000
10	11	Павел	33	Администратор	Администрация	55000
11	12	Светлана	26	Тестировщик	Тестирование	67000
12	13	Роман	42	Финансист	Финансы	105000
13	14	Татьяна	37	Редактор	Редакция	72000
14	15	Николай	39	Логист	Логистика	75000
15	16	Валерия	24	SEO-специалист	SEO	64000
16	17	Григорий	50	Бухгалтер	Бухгалтерия	110000
17	18	Юлия	45	Директор	Финансы	150000
18	19	Степан	41	Экономист	Экономика	98000
19	20	Василиса	38	Проект-менеджер	Продажи	88000
20	21	Антон	32	Разработчик	IT	85000
21	22	Елена	28	Аналитик	Маркетинг	70000
22	23	Игорь	35	Менеджер	Продажи	120000
	_					
0	Ста	ж работы К 2	атегория.	•		
1		5		Средняя Средняя		
2		15		Средняя		
3		7		Средняя		
4		3		Низкая		
5		6		Средняя		
6		12		Низкая		
7		4		Средняя		
8		10		Средняя		
9		5		Средняя		
10		7		Низкая		
11		2		Средняя		
12		20		Высокая		
13		9		Средняя		
14		11		Средняя		
15		3		Средняя		
16		25		Высокая		
17		20		Высокая		
18		14		Средняя		
19		8		Средняя		
20		6		Средняя		
21		3		Средняя		
22		8		Высокая		
		_				

Рисунок 18. Выполненное задание

#### Задание 5. Удаление строк и столбцов

```
import pandas as pd
 # Создаем DataFrame с данными
         'Стаж работы': [2, 5, 15, 7, 3, 6, 12, 4, 10, 5, 7, 2, 20, 9, 11, 3, 25, 20, 14, 8]
df = pd.DataFrame(data)
# 1. Удалите столбец "Категория зарплаты" с '.drop()'
# В исходных данных такого столбца нет, предположим, что он есть, добавим его для примера
# Для примера добавим его:
df['Категория зарплаты'] = ['Высокая', 'Высокая', 'Высокая', 'Высокая', 'Низкая', 'Высокая', 'Кредняя', 'Средняя', 'Сред
# 2. Удалите строку с ID = 10
df = df[df['ID'] != 10]
# 3. Удалите все строки, где стаж работы < 3 лет
df = df[df['CTax pa6oTb'] >= 3]
# 4. Удалите все столбцы, кроме 'Имя', 'Должность', 'Зарплата' df = df[['Имя', 'Должность', 'Зарплата']]
 # Выводим итоговый DataFrame
print(df)
```

#### Рисунок 19. Код для выполнения задания

	Имя Должность		Зарплата
1	Ольга	Аналитик	75000
2	Алексей	Менеджер	90000
3	Мария	Программист	80000
4	Сергей	Специалист	50000
5	Анна	Разработчик	85000
6	Дмитрий	HR	48000
7	Елена	Маркетолог	70000
8	Виктор	Юрист	95000
10	Павел	Администратор	55000
12	Роман	Финансист	105000
13	Татьяна	Редактор	72000
14	Николай	Логист	75000
15	Валерия	SEO-специалист	64000
16	Григорий	Бухгалтер	110000
17	Юлия	Директор	150000
18	Степан	Экономист	98000
19	Василиса	Проект-менеджер	88000

Рисунок 20. Выполненное задание

#### Задание 6. Фильтрация данных ( query , isin , between )

```
import pandas as pd
 # Создаем DataFrame с данными из таблицы
         'Баланс на счете': [120000, 80000, 150000, 200000, 95000, 300000, 140000, 175000, 110000, 9800,
                                                         250000, 210000, 135000, 155000, 125000, 180000, 275000, 320000, 105000, 90000],
          'Кредитная история': ['Хорошая', 'Средняя', 'Плохая', 'Хорошая', 'Средняя', 'Отличная', 'Средняя', 'Хорошая', 'Средняя', 'Средняя', 'Плохая', 'Средняя', 'Плохая', 'Отличная', 'Хорошая', 'Средняя', 'Плохая', 'Плохая', 'Отличная', 'Хорошая', 'Средняя', 'Плохая', 'Плохая', 'Средняя', 'Сред
df = pd.DataFrame(data)
  # 1. Выбираем всех клиентов из "Москва" или "Санкт-Петербург"
clients_moscow_spb = df[df['Город'].isin(['Москва', 'Санкт-Петербург'])]
 # 2. Выбираем клиентов, у которых баланс на счете от 100000 до 250000
clients_balance = df[df['Баланс на счете'].between(100000, 250000)]
 # 3. Отфильтровать клиентов, у которых "Кредитная история" = "Хорошая" и "Баланс на счете" > 150000
clients_credit_balance = df[
         (df['Кредитная история'] == 'Хорошая') & (df['Баланс на счете'] > 150000)
# Вывод результатов
print("Клиенты из Москвы или Санкт-Петербурга:")
print(clients_moscow_spb)
print("\nКлиенты с балансом от 100000 до 250000:")
print(clients_balance)
print("\nКлиенты с хорошей кредитной историей и балансом > 150000:")
print(clients_credit_balance)
```

# Рисунок 21. Код для выполнения задания

Клиенты из Москвы или Санкт-Петербурга:							
	ID	Имя Воз	враст	Город	Баланс на	счете Кре	дитная история
0	1	Иван	34	Москва	1	120000	Хорошая
1	2	Ольга	27 Ca	нкт-Петербург		80000	Средняя
Кли	енть	гс балансо	ом от 100	000 до 250000:			
	ID	Имя	Возраст	Гор	од Баланс	на счете	Кредитная история
0	1	Иван	34	Моск	ва	120000	Хорошая
2	3	Алексей	45	Каза	НЬ	150000	Плохая
3	4	Мария	38	Новосибир	CK	200000	Хорошая
6	7	Дмитрий	31	Челябин	ск	140000	Средняя
7	8	Елена	40	Краснод	ар	175000	Хорошая
8	9	Виктор	28	Ростов-на-До	ну	110000	Плохая
10	11	Павел	46	Ом	ck	250000	Средняя
11	12	Светлана	37	Пер	мь	210000	Отличная
12	13	Роман	41	Тюме	НЬ	135000	Средняя
13	14	Татьяна	25	Сарат	ов	155000	Хорошая
14	15	Николай	39	Сама	pa	125000	Средняя
15	16	Валерия	42	Волгогр	ад	180000	Плохая
18	19	Степан	30	Хабаров	CK	105000	Средняя
Кли	енты	гс хорошей	й кредитн	ой историей и	балансом >	150000:	
	ID	Имя	Возраст	Город	Баланс на о	счете Кред	итная история
3	4	Мария	38	Новосибирск	26	99999	Хорошая
7	8	Елена	40	Краснодар	17	75000	Хорошая
13	14	Татьяна	25	Саратов	19	55000	Хорошая
17	18	Юлия	50	Иркутск	32	20000	Хорошая

Рисунок 22. Выполненное задание

# Задание 7. Подсчет значений ( count , value\_counts , nunique )

```
import pandas as pd
# Создаем DataFrame с данными из таблицы
            'ID': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20],
            'Имя': ['Иван', 'Ольга', 'Алексей', 'Мария', 'Сергей', 'Анна', 'Дмитрий', 'Елена', 'Виктор', 'Алиса',
'Павел', 'Светлана', 'Роман', 'Татьяна', 'Николай', 'Валерия', 'Григорий', 'Юлия', 'Степан', 'Василиса'],
         'Возраст': [34, 27, 45, 38, 29, 50, 31, 40, 28, 33, 46, 37, 41, 25, 39, 42, 49, 50, 30, 35],
'Город': ['Москва', 'Санкт-Петербург', 'Казань', 'Новосибирск', 'Екатеринбург', 'Воронеж', 'Челябинск', 'Краснодар', 'Ростов-на-Дону', 'Уфа', 'Омск', 'Пермь', 'Тюмень', 'Саратов', 'Самара', 'Волгоград', 'Барнаул', 'Иркутск', 'Хабаровск', 'Томск'],
'Баланс на счете': [120000, 80000, 150000, 200000, 95000, 300000, 175000, 110000, 9800,
                                                               250000, 210000, 135000, 155000, 125000, 180000, 275000, 320000, 105000, 90000],
          'Кредитная история': ['Хорошая', 'Средняя', 'Плохая', 'Хорошая', 'Средняя', 'Отличная', 'Средняя', 'Хорошая', 'Средняя', 'Средняя',
df = pd.DataFrame(data)
# 1. Подсчет количества пропущенных значений в каждом столбце
null_counts = df.isnull().sum()
 # 2. Определение частоты встречаемости значений в столбце "Город"
city_counts = df['Город'].value_counts()
# 3. Подсчет количества уникальных значений в столбцах "Город", "Возраст" и "Баланс на счете"
unique_counts = {
           'Город': df['Город'].nunique(),
           'Bospact': df['Bospact'].nunique(),
          'Баланс на счете': df['Баланс на счете'].nunique()
# Вывод результатов
print("Количество пропущенных значений в каждом столбце:")
print(null counts)
print("\nЧастота встречаемости значений в столбце 'Город':")
print(city_counts)
print("\nКоличество уникальных значений:")
for key, value in unique_counts.items():
print(f"{key}: {value}")
```

#### Рисунок 23. Код для выполнения задания

```
Количество пропущенных значений в каждом столбце:
ID
Имя
                    0
Возраст
Город
Баланс на счете
                    0
Кредитная история
dtype: int64
Частота встречаемости значений в столбце 'Город':
Город
Москва
Санкт-Петербург
Казань
Новосибирск
Екатеринбург
Воронеж
Челябинск
Краснолар
Ростов-на-Дону
Уфа
Омск
Пермь
Тюмень
Саратов
Самара
Волгоград
Барнаул
Иркутск
Хабаровск
Томск
Name: count, dtype: int64
Количество уникальных значений:
Город: 20
Возраст: 19
Баланс на счете: 20
```

Рисунок 24. Выполненное задание

#### Задание 8. Обнаружение пропусков ( isna, notna )

```
import pandas as pd
# Создаем DataFrame с данными из таблицы
     'ID': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20],
     'Имя': ['Иван', 'Ольга', 'Алексей', 'Мария', 'Сергей', 'Анна', 'Дмитрий', 'Елена', 'Виктор', 'Алиса', 
'Павел', 'Роман', 'Татьяна', 'Николай', 'Валерия', 'Григорий', 'Юлия', 'Степан', 'Василиса', 'Пустой'], 
'Возраст': [34.0, 27.0, 45.0, 38.0, 29.0, 50.0, 31.0, 40.0, 28.0, 33.0, 46.0, 37.0, 41.0, 25.0, 42.0, 49.0, 50.0, 30.0, 35.0, None],
     'Город': ['Москва', 'Санкт-Петербург', 'Казань', 'Новосибирск', 'Екатеринбург', 'Воронеж', 'Челябинск', 'Краснодар', 'Ростов-на-Дону', 'Уфа', 'Омск', 'Пермь', 'Тямень', 'Саратов', 'Самара', 'Волгоград', 'Барнаул', 'Иркутск', 'Хабаровск', 'Томск'],
     'Баланс на счете': [120000, 80000, 150000, 200000, 95000, 300000, 140000, 175000, 110000, 9800,
                               250000, 210000, 135000, 155000, 125000, 180000, 275000, 320000, 105000, 90000],
     'Кредитная история': ['Хорошая', 'Средняя', 'Плохая', 'Хорошая', 'Средняя', 'Отличная', 'Средняя', 'Хорошая', 'Средняя', 'Средняя', 'Плохая', 'Средняя', 'Плохая', 'Отличная', 'Хорошая', 'Средняя', 'Плохая']
df = pd.DataFrame(data)
# 1. Подсчет количества пропущенных значений в каждом столбце
null_counts = df.isna().sum()
# 2. Подсчет количества заполненных значений в каждом столбце
filled_counts = df.notna().sum()
# 3. Вывести строки, где нет пропущенных значений
rows_without_na = df[df.isna().sum(axis=1) == 0]
# Вывод результатов
print("Количество пропущенных значений в каждом столбце:")
print(null counts)
print("\nКоличество заполненных значений в каждом столбце:")
print("\nСтроки без пропущенных значений:")
print(rows_without_na)
```

#### Рисунок 25. Код для выполнения задания

```
Количество пропущенных значений в каждом столбце:
TD
                    0
Имя
                    0
Возраст
                    1
                    0
Город
Баланс на счете
                    0
Кредитная история
                    0
dtype: int64
Количество заполненных значений в каждом столбце:
ID
                    20
имя
Возраст
                    19
Город
Баланс на счете
                    20
Кредитная история
dtype: int64
Строки без пропущенных значений:
   ID
            Имя Возраст
                                   Город Баланс на счете Кредитная история
                                           120000
           Иван
                 34.0
                                  Москва
                                                                   Хорошая
          Ольга
                    27.0 Санкт-Петербург
                                                    80000
                                                                   Средняя
       Алексей
                    45.0
                         Казань
Новосибирск
                                 Казань
                                                   150000
                                                                    Плохая
3
    4
          Мария
                   38.0
                                                  200000
                                                                   Хорошая
                           Екатеринбург
4
    5
        Сергей
                   29.0
                                                   95000
                                                                   Средняя
    6
           Анна
                   50.0
                                 Воронеж
                                                   300000
                                                                  Отличная
6
    7
        Дмитрий
                    31.0
                               Челябинск
                                                  140000
                                                                   Средняя
    8
          Елена
                    40.0
                               Краснодар
                                                   175000
                                                                   Хорошая
                    28.0 Ростов-на-Дону
                                                  110000
8
        Виктор
    9
                                                                    Плохая
9
   10
         Алиса
Павел
                    33.0
                                     Уфа
                                                    9800
                                                                   Средняя
                                                  250000
                                    OMCK
10
   11
                    46.0
                                                                   Средняя
                                   Пермь
                                                   210000
                    37.0
                                                                  Отличная
11
   12
          Роман
                                 Тюмень
                                                   135000
        Татьяна
                    41.0
12
   13
                                                                   Средняя
                   25.0
                                 Саратов
                                                   155000
13
   14
        Николай
                                                                   Хорошая
   15
                                                   125000
                                                                   Средняя
14
        Валерия
                   42.0
                                  Самара
                             Волгоград
15
   16
      Григорий
                   49.0
                                                   180000
                                                                    Плохая
                   50.0
          Юлия
                                                   275000
16
   17
                                                                  Отличная
                                Барнаул
17
   18
         Степан
                                                   320000
                    30.0
                                 Иркутск
                                                                   Хорошая
                   35.0
   19
       Василиса
                               Хабаровск
                                                                   Средняя
```

Рисунок 26. Выполненное задание

#### Индивидуальное задание:

```
import pandas as pd
# Создаем начальный DataFrame
columns = ['Пункт назначения', 'Номер поезда', 'Время отправления']
train_data = pd.DataFrame(columns=columns)
# Функция для ввода данных
def input train():
    destination = input("Введите пункт назначения: ")
    train_number = input("Введите номер поезда: ")
    departure_time = input("Введите время отправления (в формате HH:MM): ")
    return {columns [0] : destination, columns [1] : train_number, columns [2] : departure_time}
# Ввод данных (например, 3 записи)
for _ in range(3):
    row = input_train()
    # Используем pd.DataFrame([row]) для добавления
    train_data = pd.concat([train_data, pd.DataFrame([row])], ignore_index=True)
# Сортируем по пункту назначения
train_data = train_data.sort_values(by='Пункт назначения')
# Ввод времени для фильтрации
time_threshold = input("Введите время для фильтрации (в формате HH:MM): ")
# Преобразуем строки в datetime
train_data['Время отправления'] = pd.to_datetime(train_data['Время отправления'], format='%H:%M')
time_threshold_dt = pd.to_datetime(time_threshold, format='%H:%M')
# Фильтр по времени
filtered_trains = train_data[train_data['Время отправления'] > time_threshold_dt]
# Вывод результата
if filtered_trains.empty:
    print("Поездов, отправляющихся после указанного времени, нет.")
else:
    print("Поезда, отправляющиеся после указанного времени:")
    print(filtered_trains)
Введите пункт назначения: Ставрополь
Введите номер поезда: 3
Введите время отправления (в формате НН:ММ): 12:30
Введите пункт назначения: Зеленокумск
Введите номер поезда: 3
Введите время отправления (в формате НН:ММ): [r↓ for history. Search history with c-↑/c-↓
```

Рисунок 27. Выполненное задание

#### Ответы на контрольные вопросы:

# 1. Как создать pandas.DataFrame из словаря списков?

Ответ:

Использовать конструктор pd.DataFrame() и передать словарь, где ключи — имена столбцов, а значения — списки данных. Например:

```
df = pd.DataFrame({'Столбец1': [1, 2], 'Столбец2': [3, 4]})
```

# 2. В чем отличие создания DataFrame из списка словарей и словаря списков?

Ответ:

- Из списка словарей создается DataFrame, где каждый словарь строка.
- Из словаря списков создается DataFrame, где ключи столбцы, а списки данные по столбцам.

# 3. Как создать pandas. Numpy из массива NumPy?

Ответ:

import numpy as np
import pandas as pd
array = np.array([[1, 2], [3, 4]])
df = pd.DataFrame(array)

# 4. Как загрузить DataFrame из CSV-файла, указав разделитель?

Ответ:

Использовать функцию pd.read\_csv(), указав параметр sep. Например:  $df = pd.read\_csv('\phi a ar{u} \pi.csv', sep=';')$ 

5. Как загрузить данные из Excel в pandas и выбрать конкретный лист?

Ответ:

Использовать pd.read\_excel(), указав название листа через параметр sheet\_name:

df = pd.read\_excel('файл.xlsx', sheet\_name='Лист1')

# 6. Чем отличается чтение данных из JSON и Parquet?

Ответ:

- JSON это текстовый формат, легко читаемый человеком и обычно используемый для обмена данными между системами.
- Parquet это бинарный колонковый формат, предназначенный для эффективного хранения и быстрого чтения больших объемов данных.

## 7. Как проверить тип данных в DataFrame после загрузки?

Ответ:

Использовать type() или df.dtypes. Например:

type(df)

df.dtypes

# 8. Как определить размер DataFrame (количество строк и столбцов)?

Ответ:

Использовать df.shape. Например:

rows, columns = df.shape

# 9. В чем разница между .loc[] и .iloc[]?

Ответ:

- .loc[] доступ по меткам индексов и названиям столбцов.
- .iloc[] доступ по позициям (целым числам) строк и столбцов.

# 10. Как получить строку с индексом "Мария" из DataFrame?

Ответ:

Использовать .loc[]:

df.loc['Мария']

# 11. Как получить строку с индексом "Паша" из DataFrame?

Ответ:

df.loc['Паша']

## 12. Чем .at[] отличается от .loc[]?

Ответ:

- .at[] быстрый доступ к одному элементу по метке.
- .loc[] доступ к одному или нескольким элементам по меткам.

# 13. В каких случаях .iat[] работает быстрее, чем .iloc[]?

Ответ:

Когда нужно быстро получить один элемент по позиции (целым числом).

14. Как выбрать все строки, где "Город" равен "Москва" или "СПБ", используя .isin()?

Ответ:

df[df['Город'].isin(['Москва', 'СПБ'])]

15. Как отфильтровать DataFrame, оставив только строки, где "Возраст" от 25 до 35 лет?

Ответ:

 $df[(df['Bospact'] \ge 25) & (df['Bospact'] \le 35)]$ 

16. В чем разница между .query() и .loc[] для фильтрации данных?

Ответ:

- .query() использует строковый синтаксис, похожий на SQL.
- .loc[] более универсален, позволяет фильтровать по меткам и условиям.

# 17. Как использовать переменные Python внутри .query()?

Ответ:

Использовать @ для вставки переменной:

Lua

age\_limit = 30 df.query('Bospact > @age\_limit')

# 18. Как узнать, сколько пропущенных значений в каждой колонке DataFrame?

Ответ:

Использовать .isna().sum():

df.isna().sum()

# 19. В чем разница между .isna() и .notna()?

Ответ:

- .isna() возвращает True для пропущенных значений (NaN).
- .notna() возвращает True для заполненных значений.
- 20. Как вывести только строки, где нет пропущенных значений?

Ответ:

df.dropna()

21. Как добавить новый столбец "Категория" с фиксированным значением "Неизвестно"?

Ответ: df['Kатегория'] = 'Неизвестно'

# 22. Как удалить строку по индексу?

Ответ:

df.drop(index)

# 23. Как удалить столбец "Возраст"?

Ответ:

df.drop('Возраст', axis=1)

## 24. Как удалить все строки, содержащие хотя бы один NaN?

Ответ:

df.dropna(how='any')

# 25. Как удалить столбцы, содержащие хотя бы один NaN?

Ответ:

df.dropna(axis=1, how='any')

# 26. Как посчитать количество пустых значений в каждом столбце?

Ответ:

Использовать .isna().sum(), как в вопросе 18.

# 27. Чем .value\_counts() отличается от .nunique()?

Ответ:

- .value\_counts() считает количество уникальных значений и их частоты.
  - .nunique() возвращает число уникальных значений.

# 28. Как определить, сколько раз встречается каждое значение в столбце "Город"?

Ответ:

df['Город'].value counts()

# 29. Почему display(df) лучше, чем print(df) в Jupyter Notebook?

Ответ:

display() показывает DataFrame в виде хорошо отформатированной таблицы, а print() — в виде текста, что менее удобно для визуального восприятия.

# 30. Как изменить максимальное количество строк, отображаемых в DataFrame в Jupyter Notebook?

Ответ:

Использовать настройку pandas:

pd.set\_option('display.max\_rows', 100)

**Вывод:** в ходе лабораторной работы познакомились с основами работы с библиотекой pandas, в частности, а также ознакомились со структурой данных Series.